

Un RAG portable sobre SUDOCU: consulta conversacional de la normativa de las universidades nacionales con estados de diálogo con procedencia

Juan Manuel Fernández¹, Francisco Tamasi¹, Sebastián Marchetti¹, and Mario Oloriz¹

Universidad Nacional de Luján, Luján, Argentina
{jmfernandez,ftamasi,smarchetti}@unlu.edu.ar

Resumen La normativa de una universidad nacional es pública, pero encontrarla exige saber de antemano qué acto la contiene. Presentamos un asistente conversacional de consulta de normativa institucional, portable entre las universidades que publican en el módulo de publicación de SUDOCU, e instanciado sobre los 21.364 actos administrativos de la Universidad Nacional de Luján, fragmentados por unidad normativa y recuperados de forma híbrida sobre metadatos autoritativos del sistema de origen. El sistema mantiene un estado de diálogo con dos ranuras —la entidad de la que se habla y los actos en juego— que no completan un esquema fijo sino que *pesan* la recuperación. La contribución central es que ese peso lo determina la *procedencia* del valor: lo que infiere el sistema refuerza de forma débil; lo que la persona fija —visible y editable en la interfaz— pesa más y no se sobrescribe. Evaluamos recuperación, ablación de cada mecanismo, fidelidad de citas y validación con evaluadores del dominio. La ingesta completa —catálogo, descarga, vectorización, indexación— se opera desde el panel del propio sistema, y la portabilidad está verificada: una segunda instancia corre sobre el portal de la Universidad Nacional de San Luis con el mismo código y solo configuración.

Keywords: Generación aumentada por recuperación, Estado de diálogo, Documentos normativos, Metadatos estructurados, Sistemas desplegados.

1. Introducción

La normativa de una universidad nacional argentina es pública y está en línea. Sin embargo, consultarla supone un conocimiento previo que la mayoría de sus destinatarios no tiene: para encontrar una resolución hay que saber, con razonable precisión, qué resolución se busca. Los portales de publicación documental ofrecen búsqueda por número, por tipo de acto y por órgano emisor, pero no por lo que a una persona efectivamente le pasa: necesita saber qué dice la normativa sobre una licencia, sobre una designación o sobre un plan de estudios, sin tener idea de qué acto lo establece.

Este trabajo presenta un asistente conversacional sobre el digesto de la Universidad Nacional de Luján (UNLu), construido sobre los 21.364 actos administrativos publicados en su portal SUDOCU desde abril de 2024. El sistema responde en lenguaje natural y cita los fragmentos normativos que sustentan cada afirmación, de modo que toda respuesta puede rastrearse hasta el documento original.

El problema no se agota en la recuperación de un solo turno. Consultar normativa es conversacional por naturaleza: se pregunta por un tema, se identifica un acto y se repregunta sobre su articulado. Esas repreguntas no se sostienen solas —“¿y qué dice el artículo 2?”— y en castellano suelen omitir el sujeto, lo que agrava el problema: “¿está en alguna comisión?” es “¿[ella] está en alguna comisión?” y no contiene ningún pronombre que delate la dependencia del contexto.

Los sistemas orientados a tareas resuelven esto manteniendo un estado de diálogo que resume la conversación [16,15]. Aquí adoptamos esa idea pero con un destino distinto: el estado no completa los campos de una consulta a una base con esquema conocido, sino que *pesa* la recuperación sobre un corpus documental abierto, apoyándose en los metadatos estructurados que el sistema de origen ya provee.

Sobre esa base introducimos el aporte central del trabajo. En la literatura, la decisión de aplicar una restricción de manera dura o blanda depende de la incertidumbre del modelo, del tipo de atributo o de la arquitectura del sistema. Nosotros la hacemos depender de **quién puso el valor ahí**: una entidad inferida por el sistema refuerza débilmente la recuperación, mientras que una entidad fijada por el usuario —que ve el estado y puede editarlo— pesa más y el modelo deja de sobrescribirla. La corrección del usuario no es solo una enmienda: es una afirmación con mayor confianza que la que el sistema puede tener por sí mismo, y el sistema la trata como tal.

Las contribuciones de este artículo son:

1. Un sistema desplegado de consulta conversacional sobre normativa universitaria, con trazabilidad completa desde cada afirmación hasta el PDF publicado, y fragmentación por unidad normativa (Visto, Considerando, parte resolutive, artículos, anexos) que sigue la forma jurídica del acto administrativo argentino.
2. Un estado de diálogo cuya *procedencia* determina el régimen de recuperación, visible y editable por quien consulta, con ablación de cada mecanismo por separado.
3. Un análisis empírico del corpus que expone un límite estructural: la Universidad no registra qué norma deroga o modifica a cuál, de modo que ningún sistema construido sobre este digesto puede afirmar vigencia. Sostenemos que explicitar ese límite es parte del diseño, no una omisión.
4. Portabilidad verificable: SUDOCU es un sistema de alcance nacional y el módulo de publicación documental es un componente estándar suyo. La superficie de adaptación a otra universidad es la URL del portal —las carpetas

se descubren automáticamente— y una sonda de tres pedidos de solo lectura responde, antes de comprometerse, si esa instalación es compatible.

El resto del artículo se organiza así. La Sección 2 revisa el trabajo relacionado. La Sección 3 describe el corpus y su construcción. La Sección 4 detalla el sistema. La Sección 5 presenta el protocolo de evaluación y la Sección 6 los resultados. La Sección 7 concluye.

2. Trabajo relacionado

La aplicación de IA en la educación superior crece aceleradamente, pero con una asimetría documentada: solo el 11 % de los estudios se orienta a la gestión y administración, frente al 72 % centrado en estudiantes [4], y buena parte de la literatura describe potencialidades antes que implementaciones consolidadas [5]. Los antecedentes funcionales más cercanos son asistentes de consulta de rutina sobre políticas académicas [12], sin recuperación sobre el corpus normativo ni trazabilidad a la norma publicada. Este trabajo se ubica en esa vacancia —particularmente aguda en el contexto latinoamericano— con un sistema desplegado de consulta normativa para la gestión universitaria.

2.1. Recuperación aumentada sobre corpus normativos

La recuperación aumentada por generación [9] se aplicó a dominios legales y regulatorios, donde la exigencia de citar la fuente es mayor que en dominio abierto: una afirmación sin respaldo no es un error menor sino un riesgo. El área sobre digestos universitarios latinoamericanos está poco poblada; el trabajo más cercano que encontramos opera sobre un corpus de un orden de magnitud menor.

2.2. Estado de diálogo como filtro de recuperación

El seguimiento del estado de diálogo es estándar en sistemas orientados a tareas [16,15], donde las ranuras completan una consulta a una base con esquema cerrado y conocido. Varios trabajos recientes lo usan, en cambio, para restringir la recuperación. ShopTalk [11] convierte el estado de diálogo en una combinación de consulta textual y restricciones de faceta, y ya combina un régimen duro y uno blando según el atributo esté o no anclado al catálogo. Thulke et al. [14] usan el contexto del diálogo para acotar jerárquicamente el espacio de candidatos antes del *ranking*. RA-Rec [6] nombra explícitamente restricciones duras y blandas en el esquema del estado, aunque las resuelve colapsadas en una consulta en lenguaje natural.

Nuestro sistema comparte con estos trabajos el uso del estado como señal de recuperación. Se diferencia en dos puntos: el corpus es documental y abierto —no un catálogo de ítems ni un esquema tipo MultiWOZ— y, sobre todo, el régimen de aplicación no lo decide la incertidumbre del modelo ni el tipo de atributo, sino la procedencia del valor.

2.3. Transparencia y control del usuario

Que el usuario pueda inspeccionar y corregir lo que un sistema infirió es un principio establecido, de los sistemas *penetrables* de Koenemann y Belkin [7] al ciclo de explicación y corrección de Kulesza et al. [8]. En diálogo orientado a tareas, SOVITE [10] muestra las ranuras detectadas y permite repararlas por manipulación directa; en recuperación, propuestas recientes plantean exponer y dejar editar la intención inferida [1].

Reconocemos explícitamente que la idea de mostrar y dejar editar el estado inferido *no es nueva*. Nuestro aporte no es la editabilidad en sí, sino vincularla a un régimen de recuperación: la procedencia del valor determina cuánto pesa. A eso se suma que, a diferencia de las propuestas citadas, aquí se trata de un sistema en operación sobre un corpus institucional real.

3. El corpus

3.1. Origen e ingesta

La UNLu publica sus actos administrativos en un portal SUDOCU, sistema de gestión documental desarrollado por la Universidad Nacional de General Sarmiento y adoptado por el sistema universitario nacional. Una primera recolección por interfaz obtuvo 19.959 documentos en PDF; la recolección definitiva se hace contra la API del propio portal —la misma que su interfaz usa por dentro— y obtiene, por cada acto, sus metadatos desglosados (tipo, código, número, fecha, título, órgano emisor), su identificador interno y una URL permanente al PDF oficial. El catálogo completo reúne **21.344** actos en once carpetas, y la completitud se afirma contra el total que el portal declara por carpeta, no se supone. Tras depurar actos duplicados y reparar identidades degradadas con el catálogo, el índice servido contiene **21.364** documentos y **151.696** fragmentos.

El corpus abarca desde abril de 2024, fecha de puesta en producción del portal. El digesto histórico anterior, de aproximadamente 120.000 documentos, tiene otra fisonomía y no está incorporado aún.

[JM: párrafo de origen reescrito para reflejar la recolección por API y la depuración; revisar si el nivel de detalle te cierra.]

3.2. Unión con los metadatos autoritativos

La unión entre cada PDF y su fila de metadatos merece detalle porque expone un riesgo general de estas ingestas. El proceso de descarga renombra archivos de forma posicional, y verificamos que 1.780 archivos habían sido renumerados por fecha de creación, lo que rompía silenciosamente la correspondencia posicional. Un sistema construido sobre esa unión habría citado fechas y números equivocados con total aplomo.

Resolvimos la unión por doble vía: la posicional y la basada en el código de acto impreso en el propio documento. Ante desacuerdo prevalece el código, por ser la identidad del acto. El resultado, medido sobre el índice servido: el

81,6 % de los fragmentos con ambas vías en acuerdo (confianza alta), el 18,4 % resuelto por una sola vía (confianza media, marcada como tal), y los conflictos —ambas vías resolviendo a actos distintos— excluidos por regla; el 99,6 % de los fragmentos queda enlazado al PDF oficial.

3.3. Fragmentación por unidad normativa

Un acto administrativo argentino tiene una estructura reconocible: Visto, Considerando, parte resolutive, artículos numerados, firmas y anexos. Fragmentamos siguiendo esa estructura en lugar de por ventanas de tamaño fijo, de modo que cada fragmento sea una unidad citable. Se obtuvieron **140.902** fragmentos (7,1 por documento), de los cuales **51.901** corresponden a artículos.

Esta decisión tiene una consecuencia práctica: la unidad de cita coincide con la unidad de recuperación, de modo que una respuesta puede referir “*artículo 2 de la disposición X*” y enlazar exactamente a ese texto.

3.4. Un límite estructural: la vigencia

La Universidad **no lleva registro de qué norma deroga o modifica a cuál**. Ese dato no existe en ningún sistema institucional. El campo de estado que publica el portal no representa vigencia.

La consecuencia es directa y no admite solución técnica desde este corpus: ningún sistema construido sobre él puede afirmar que una norma esté vigente. Puede decir qué dispuso un acto y en qué fecha; no puede decir que siga en vigor. Optamos por hacerlo explícito en la interfaz, en la documentación y en las instrucciones dadas al modelo generador, que tiene prohibido afirmar vigencia. Lo reportamos como hallazgo: es una característica del estado de digitalización de la normativa universitaria, no una limitación de la implementación.

4. El sistema

4.1. Recuperación híbrida

Combinamos una señal densa y una léxica. La densa usa BGE-m3 [2] (1.024 dimensiones) sobre los 140.902 fragmentos. La léxica es una implementación propia de BM25 [13] con un tokenizador que *preserva los identificadores normativos*: expresiones como RESHCS-LUJ: 0000042-24, 528/2025 o DISPCD-CB se mantienen como unidades en lugar de partirse, porque son justamente lo que la señal densa no distingue. Las dos listas se fusionan con *reciprocal rank fusion* [3].

Cuando la consulta nombra un acto concreto, la búsqueda se restringe a los documentos que llevan ese número. La fusión por sí sola no lo garantiza: un documento con dos señales tibias supera a uno con una señal decisiva. Además, el número solo no alcanza, porque cada tipo de acto lleva numeración propia y un mismo número existe en decenas de códigos distintos.

4.2. Estado de diálogo

El estado tiene dos ranuras:

- **entidad:** el sujeto del que se viene hablando (persona, carrera, departamento, órgano). Cardinalidad uno, semántica de reemplazo.
- **actos:** los actos administrativos mencionados. Conjunto que acumula.

El criterio para admitir una ranura fue restrictivo: *una ranura se justifica solo si transporta entre turnos información que el texto de la consulta actual no tiene*. Un filtro temporal, por ejemplo, no lo cumple: cuando el año es pertinente el usuario suele reescribirlo, y arrastrarlo desde turnos anteriores hace más daño que bien.

4.3. Procedencia y peso

Cada valor del estado lleva su **procedencia**, y de ella se deriva su peso:

Procedencia			Peso	Significado
sistema	0,5	inferido por el modelo a partir de la conversación		
usuario	1,0	fijado explícitamente por quien consulta		
descartado	0,0	apagado por el usuario; permanece visible		

El peso entra como bonificación aditiva sobre el puntaje ya fusionado:

$$\text{puntaje}(d) = \text{RRF}(d) + \sum_{s \in S} w_s \cdot \mathbb{K}[d \models s] \cdot u \quad (1)$$

donde S es el conjunto de ranuras activas, w_s el peso derivado de la procedencia y $u = 1/(K+1)$ la unidad de bonificación, es decir, lo que vale encabezar una de las dos señales. Expresarla en unidades de RRF evita una constante arbitraria y acota el efecto: una ranura empuja, pero no puede sustituir a la relevancia semántica, que suma por las dos señales.

Ninguna ranura excluye documentos. Un valor mal inferido degrada el orden pero no puede vaciar el resultado, que es el modo de falla que vuelve inutilizable a un filtro duro.

4.4. Estado visible y editable

El estado se muestra sobre el campo de escritura y es editable: se puede corregir la entidad, descartar un acto y volver a incorporarlo. Lo descartado no se borra, se muestra atenuado, porque saber qué infirió el sistema es parte de poder controlarlo.

Editar tiene dos efectos, y esa es la instanciación concreta del aporte descrito en la Sección 4.3: el valor pasa a pesar el doble en la Ecuación 1, y el modelo deja de sobrescribirlo en los turnos siguientes. Además, cuando el usuario fijó una entidad y la consulta con la que se buscará no la menciona, el sistema lo declara en la interfaz en lugar de resolver la discrepancia en silencio.

5. Protocolo de evaluación

5.1. Evaluación automática de la recuperación

No existe un conjunto anotado de consultas sobre este corpus. Construimos tres conjuntos con verdad de referencia, por muestreo estratificado de fragmentos por sección del portal y tipo de acto —sin estratificar, el conjunto queda dominado por las secciones grandes y no informa sobre las demás—:

Consultas por identificador ($n = 30$). Se toma un documento y se pregunta por su código y número, con plantillas fijas y sin intervención de ningún modelo. El documento correcto se conoce de antemano, de modo que las métricas son deterministas y no intervienen juicios.

Consultas por contenido ($n = 131$). Se genera con un modelo de lenguaje, a partir de un fragmento, la consulta que haría quien necesita esa información sin tener el documento delante, con dos restricciones: no nombrar el número del acto y no copiar frases textuales. Cada par pasa por un control de calidad automático —un segundo pase que decide, con el fragmento y la consulta a la vista, si el primero responde a la segunda— y lo que no pasa se descarta y se reporta (34,5 % descartado). Es la construcción habitual cuando no hay anotación disponible, y su limitación debe declararse: mide la recuperación contra un sustituto de la necesidad de información, no contra la necesidad real. Por eso la validación con evaluadores del dominio (Sección 5.4) no es complementaria sino necesaria: mide otra cosa.

Consultas conversacionales ($n = 58$: 29 temáticas y 29 ancladas en un acto). Dos turnos generados desde un mismo fragmento: el primero establece el tema y el segundo es una repregunta que no se sostiene sola (“¿y de qué año es?”). Son el banco de prueba de los mecanismos de estado de la Sección 4.3.

La relevancia se decide a nivel *acto*: recuperar cualquier fragmento del acto del que salió la consulta cuenta como acierto, porque el sistema cita y enlaza actos completos. Reportamos Recall@ k , MRR@10 y nDCG@10.

5.2. Ablación

Sobre las consultas simples ablamos las señales de recuperación: denso solo, léxico solo y la fusión híbrida con anclaje de identificadores. Sobre las conversacionales ablamos un mecanismo de estado por vez a partir de la configuración completa —reescritura de la repregunta, ranura de entidad, ranura de actos—, más las dos condiciones extremas: el segundo turno sin ningún estado, y el estado con la entidad *corregida*, en la que la ranura pesa como fijada por el usuario. Esta última simula la corrección humana bajo el supuesto de que la inferencia era correcta; donde no lo era, el peso doble castiga, y ese costo también se reporta. Es la comparación que sostiene el aporte sobre procedencia.

Reranking. Medimos además si un *cross-encoder* aporta sobre el orden del híbrido: el sistema recupera su top-50 y un reranker de la misma familia que el

codificador denso (BGE-reranker-v2-m3) lo reordena, sin poder traer documentos nuevos. Eso aísla la pregunta relevante —¿el orden es el cuello de botella?— de la cobertura, que se mide aparte.

5.3. Fidelidad de las citas

Dos verificaciones deterministas, sin juez: (i) todo acto citado en la respuesta debe estar entre lo recuperado —citar algo no recuperado equivale a inventarlo— y (ii) en consultas sobre personas, el fragmento citado debe contener efectivamente el nombre de la persona a la que se le atribuye algo.

5.4. Validación con evaluadores del dominio

Las métricas automáticas no responden la pregunta que decide la adopción: si una persona del dominio se apoyaría en las respuestas. Tres evaluadores con distinta relación con la normativa —un estudiante, un docente de la División Matemática y un jefe de división con rol de gestión— completan un único cuestionario sobre la configuración completa del sistema (la ganadora de la evaluación automática): diez consultas fijas con sus respuestas congeladas —idénticas entre evaluadores, lo que permite reportar acuerdo— y tres consultas propias de su trabajo, hechas en vivo. Cada respuesta se puntúa en escala Likert de 1 a 5 en cuatro dimensiones (utilidad, fidelidad a las citas, completitud y claridad), con marca explícita de contenido incorrecto; un bloque final puntúa confianza, ventaja sobre el método actual de búsqueda y disposición a que la Universidad lo ofrezca abiertamente.

Cuadro 1. Validación con evaluadores: mediana (mín–máx) por dimensión sobre los ítems fijos, y bloque global.

	E1 (estudiante)	E2 (docente)	E3 (gestión)
Utilidad	[pendiente]	[pendiente]	[pendiente]
Fidelidad	[pendiente]	[pendiente]	[pendiente]
Completitud	[pendiente]	[pendiente]	[pendiente]
Claridad	[pendiente]	[pendiente]	[pendiente]
Confianza	[pendiente]	[pendiente]	[pendiente]
Ventaja	[pendiente]	[pendiente]	[pendiente]
Adopción	[pendiente]	[pendiente]	[pendiente]

6. Resultados

[Los numeros de recuperacion, procedencia y citas son mediciones reales sobre el indice depurado (agosto 2026). Quedan pendientes solo la tabla de jueces y las dos cifras del parrafo de reranking.]

6.1. Recuperación y ablación

Cuadro 2. Recuperación por tipo de consulta: cada señal sola y la fusión híbrida con anclaje de identificadores.

Configuración	Identificador			Contenido		
	R@5	MRR@10	nDCG@10	R@5	MRR@10	nDCG@10
Denso solo	0.100	0.075	0.081	0.779	0.645	0.689
Léxico solo	0.833	0.683	0.757	0.786	0.682	0.715
Híbrido (sistema)	1.000	1.000	1.000	0.824	0.721	0.753

El reranking no aporta: reordenar el top-50 del híbrido con el cross-encoder deja las métricas iguales o peores (R@1 global 0,677 contra 0,702 del híbrido, y en identificadores cae de 1,000 a 0,967), y en las consultas por identificador las *empeora*, porque el reranker puntúa por contenido y desconoce el anclaje exacto que esas consultas necesitan. A cambio multiplica el costo por consulta. La fusión RRF con anclaje de identificadores ya resuelve el ordenamiento en este dominio, y el resultado —negativo— evita cargar al sistema desplegado con un componente que no paga su latencia.

6.2. Procedencia del estado

La Tabla 3 aísla cada mecanismo de estado sobre las consultas conversacionales, separadas en dos poblaciones: las temáticas, donde el primer turno establece un tema, y las ancladas en un acto, donde el primer turno lo nombra por su número y el segundo es puramente elíptico (“¿y de qué fecha es?”).

Tres lecturas se sostienen sobre esa tabla. Primera: sin ningún mecanismo, la repregunta elíptica es irrecuperable —en las ancladas en un acto no se recupera nada, porque el turno no contiene ni el tema ni el número—. Segunda: la *reescritura* de la consulta con el historial es el mecanismo dominante en diálogos de dos turnos: al reponer el sujeto omitido, la consulta reescrita vuelve a ser autocontenida, y sobre ella el anclaje de identificadores y la recuperación híbrida hacen el resto. Tercera: cuando la reescritura ya repuso el sujeto, las ranuras no mueven las métricas de este conjunto; su papel observable es el de *seguro*, no el de motor. La ranura de actos sostiene la continuidad cuando la conversación sigue sobre normativa ya citada, y la garantía de entidad interviene en el caso exacto en que la recuperación se fue de tema, que es el mecanismo detrás de la verificación de atribución de la Sección 6.3. Esta lectura es consistente con el diseño: en diálogos cortos con consultas reescritas autocontenidas hay poco margen para que un sesgo suave reordene el tope del ranking, y el valor de la procedencia se juega en el régimen de interacción —qué puede fijar quien consulta y qué deja de ser sobrescrito— más que en el delta de recuperación de un turno.

Cuadro 3. Consultas conversacionales: ablación de los mecanismos de estado y efecto de la procedencia, por población. La configuración completa usa la consulta reescrita, la ranura de entidad y la de actos con pesos de inferencia.

Condición	Temáticas			Ancladas en un acto		
	R@5	MRR@10	nDCG@10	R@5	MRR@10	nDCG@10
Sin estado (turno 2 solo)	0.241	0.149	0.173	0.000	0.000	0.000
– reescritura	0.241	0.185	0.223	0.069	0.025	0.050
– ranura entidad	0.862	0.756	0.790	1.000	1.000	1.000
– ranura actos	0.862	0.757	0.791	1.000	1.000	1.000
Completa (estado inferido)	0.862	0.757	0.791	1.000	1.000	1.000
Estado corregido (peso usuario)	0.862	0.757	0.791	1.000	1.000	1.000

6.3. Fidelidad de las citas

Cuadro 4. Verificación automática de citas y atribución sobre respuestas generadas por el sistema completo.

Verificación	Cantidad	%
Actos citados en las respuestas	133	–
Anclados en lo recuperado	129	97,0 %
Sueltos (sin fuente detrás)	4	3,0 %
Atribución de entidad nombrada correcta	23/24	95,8 %

[Queda para discutir si sumamos un conjunto de consultas sin respuesta posible (actos inexistentes) para medir la tasa de “no sé”: el protocolo actual no lo incluye.]

6.4. Portabilidad verificada en una segunda universidad

[JM: subseccion nueva — propone mover la portabilidad de trabajo futuro a resultado, con la instancia UNSL como evidencia. Si no te cierra, se vuelve al enunciado anterior.]

Verificamos la portabilidad contra el portal SUDOCU de la Universidad Nacional de San Luis. La sonda de tres pedidos dictaminó compatibilidad sin cambios; el recolector descubrió automáticamente sus 15 carpetas públicas —la UNSL publica por facultad, la UNLu por tipo de acto— y una instancia completa del asistente, con la marca y el esquema de colores de esa universidad, se construyó desde su propio panel de administración sobre un corpus declarado de 72.816 actos, sin recompilar ni bifurcar el código. Dos diferencias reales se absorbieron en el código común (la clave del código de acto en el objeto del listado y el nombre de las carpetas); la única adaptación que quedó para configuración por

universidad es la limpieza del membrete de sus PDF, cuyo esqueleto estructural (Visto, Considerando, parte resolutive, artículos) se detectó idéntico en una muestra piloto de 20 documentos.

6.5. Validación con evaluadores

Los resultados del cuestionario se vuelcan en la Tabla 1 (Sección 5.4). [\[Completar cuando los tres jueces entreguen la planilla.\]](#)

7. Conclusiones y trabajo futuro

Presentamos un asistente conversacional de consulta normativa desplegado sobre el digesto de la UNLu, con 21.364 actos y 151.696 fragmentos depurados —sin actos duplicados y con la identidad de cada fragmento tomada del catálogo del portal—, recuperación híbrida y trazabilidad completa desde cada afirmación hasta el documento publicado.

El aporte central es tratar la *procedencia* de un valor del estado de diálogo como señal de confianza que determina su peso en la recuperación. Lo que el sistema infiere refuerza débilmente; lo que el usuario fija —viendo y editando ese estado— pesa más y no es sobrescrito. [\[Cerrar con la magnitud del efecto una vez medido.\]](#)

Reportamos además un hallazgo sobre el corpus que excede a este sistema: la ausencia de registro institucional de derogaciones impide afirmar vigencia. Es una limitación del estado de digitalización de la normativa universitaria, y creemos que declararla es preferible a que un asistente proyecte una certeza que los datos no sostienen.

Como trabajo futuro: incorporar el digesto histórico anterior a abril de 2024 —unos 120.000 documentos de otra fisonomía— y validar la portabilidad ejecutando la ingesta sobre el portal de otra universidad nacional. Distinguimos dos afirmaciones que suelen confundirse: que la *ingesta* funcione en otra instalación es barato de verificar; que las *respuestas* sean buenas exige personas que conozcan esa normativa. Solo reclamamos la primera.

Agradecimientos. [\[Completar.\]](#)

Referencias

1. Anand, A., et al.: Context aware query rewriting for text rankers using LLM. In: Gen-IR Workshop at SIGIR (2023), plantea Commit / Edit / Explore sobre la intencion inferida
2. Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., Liu, Z.: BGE m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. arXiv preprint arXiv:2402.03216 (2024)
3. Cormack, G.V., Clarke, C.L.A., Buettcher, S.: Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In: Proceedings of SIGIR (2009)

4. Crompton, H., Burke, D.: Artificial intelligence in higher education: the state of the field. *International Journal of Educational Technology in Higher Education* 20, 22 (2023)
5. George, B., Wooden, O.: Managing the strategic transformation of higher education through artificial intelligence. *Administrative Sciences* 13(9), 196 (2023)
6. Kemper, S., Cui, J., Dicarantonio, K., Lin, K., Tang, D., Korikov, A., Sanner, S.: Retrieval-augmented conversational recommendation with prompt-based semi-structured natural language state tracking. In: *Proceedings of SIGIR* (2024)
7. Koenemann, J., Belkin, N.J.: A case for interaction: A study of interactive information retrieval behavior and effectiveness (1996), *distingue sistemas opacos, transparentes y penetrables*
8. Kulesza, T., Burnett, M., Wong, W.K., Stumpf, S.: Principles of explanatory debugging to personalize interactive machine learning. In: *Proceedings of IUI* (2015)
9. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.t., Rocktäschel, T., Riedel, S., Kiela, D.: Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems (NeurIPS)* (2020)
10. Li, T.J.J., Chen, J., Xia, H., Mitchell, T.M., Myers, B.A.: SOVITE: Towards automated discovery of conversational breakdowns and repairs. In: *Proceedings of UIST* (2020), *muestra intent y valores de slot y permite repararlos por manipulacion directa*
11. Manku, G.S., et al.: ShopTalk: A system for conversational faceted search. In: *SIGIR Workshop on eCommerce* (2022), *convierte el estado de dialogo en consulta textual mas restricciones de faceta*
12. Pang, W., Wei, Z.: Exploring the transformative potential of artificial intelligence in university academic management. *Education Journal* 8(3), 97–103 (2025)
13. Robertson, S., Zaragoza, H.: The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval* 3(4), 333–389 (2009)
14. Thulke, D., Daheim, N., Dugast, C., Ney, H.: Efficient retrieval augmented generation from unstructured knowledge for task-oriented dialog. In: *AAAI Workshop on DSTC9* (2021)
15. Williams, J., Raux, A., Ramachandran, D., Black, A.: The dialog state tracking challenge. In: *Proceedings of the SIGDIAL Conference* (2013)
16. Young, S., Gašić, M., Thomson, B., Williams, J.D.: POMDP-based statistical spoken dialog systems: A review. *Proceedings of the IEEE* 101(5), 1160–1179 (2013)